

Avaliação Prática Multidisciplinar

Infraestrutura de Big Data + Paradigmas e Tecnologias Emergentes

Curso: Ciência de Dados

Modalidade: atividade prática em dupla

Ambiente: AWS Academy Learner Lab

Prazo: 02/10/2026

1. Situação-problema

Uma rede varejista mantém registros diários de vendas em arquivos separados. A empresa deseja organizar esses dados em nuvem, realizar consultas analíticas e construir um modelo de Machine Learning para estimar a quantidade vendida de seus produtos.

Sua dupla foi contratada para desenvolver um **protótipo funcional de uma solução de dados e Machine Learning na AWS**, demonstrando o percurso dos arquivos recebidos até a geração e o armazenamento das previsões.

A solução deverá integrar os conteúdos das duas disciplinas por meio do seguinte fluxo:

Google Drive (opcional) → Amazon S3 → AWS Glue → Amazon Athena → Amazon SageMaker → Amazon S3

2. Dados disponibilizados

Cada dupla receberá acesso a uma pasta no Google Drive contendo uma versão do conjunto de dados, identificada entre VAREJO_01 e VAREJO_10.

A pasta contém:

Arquivo	Conteúdo
vendas_2024.csv	Histórico de vendas de 2024
vendas_2025.csv	Histórico de vendas de 2025
vendas_2026.csv	Histórico de vendas de 2026
dados_inferencia.csv	Registros para os quais a dupla deverá gerar previsões
LEIA-ME.md	Dicionário e orientações sobre os dados

Os dados são inteiramente sintéticos. O calendário simulado contempla históricos completos de 2024 a 2026 e registros de inferência para janeiro de 2027.

Cada versão possui aproximadamente 45 mil registros. As versões apresentam a mesma estrutura geral, mas possuem relações e comportamentos diferentes.

A variável a prever é quantidade_vendida. Ela não está presente no arquivo de inferência.

Os arquivos podem conter problemas de qualidade. A dupla deverá identificar essas situações e decidir como tratá-las. A presença de uma coluna no histórico não garante que ela seja adequada

como entrada do modelo: sua disponibilidade no momento da previsão também deverá ser considerada.

3. Atividades obrigatórias

Etapa 1 — Ingestão e armazenamento no Amazon S3

Baixe os arquivos da pasta atribuída à dupla e realize sua ingestão no Amazon S3.

Organize o armazenamento de forma a distinguir:

- Dados brutos;
- Dados preparados;
- Dados de inferência;
- Resultados das previsões.

Preserve os arquivos originais na área de dados brutos. Os históricos e o arquivo de inferência deverão ficar em locais separados, pois possuem esquemas diferentes.

A integração automática com a API do Google Drive não é exigida.

Etapa 2 — Preparação com AWS Glue

Utilize o AWS Glue para catalogar e processar os dados, consolidando os três arquivos históricos em uma base preparada.

A preparação deverá contemplar, conforme os problemas encontrados:

- Verificação e conversão dos tipos de dados;
- Padronização de valores e formatos;
- Identificação e tratamento de registros duplicados;
- Tratamento de valores ausentes;
- Análise de valores inválidos ou atípicos.

Grave a base preparada em **formato Parquet ou CSV no S3** e disponibilize sua estrutura no **AWS Glue Data Catalog**.

Registre as regras adotadas e seus efeitos sobre os dados. A exclusão de registros ou colunas deverá ser justificada.

Apenas executar um crawler não atende integralmente a esta etapa: deve existir uma rotina de transformação executada no AWS Glue, pode ser de forma visual.

Etapa 3 — Análise com Amazon Athena

Utilize o Amazon Athena para consultar a base preparada. Entregue pelo menos **cinco consultas SQL**, contemplando:

1. Contagem de registros por ano;
2. Quantidade vendida por loja;
3. Quantidade vendida por categoria ou produto;

4. Evolução mensal das vendas;
5. Uma verificação de qualidade dos dados.

Apresente os resultados e interprete pelo menos **dois achados relevantes** para o negócio ou para a modelagem.

Etapla 4 — Modelagem no Amazon SageMaker

Em um notebook no Amazon SageMaker, utilize os dados preparados para desenvolver um modelo de regressão que estime quantidade_vendida.

A dupla deverá:

- Selecionar os atributos de entrada e justificar sua utilização;
- Avaliar quais informações estarão disponíveis antes da venda;
- Criar atributos adicionais, caso necessário;
- Separar os dados em treinamento, validação e teste, respeitando a ordem temporal;
- Construir uma previsão de referência simples;
- Treinar pelo menos um modelo de regressão;
- Comparar o modelo com a previsão de referência;
- Apresentar **MAE e RMSE**, com interpretação dos resultados.

A divisão temporal de referência será:

Conjunto	Período
-----------------	----------------

Treinamento	Janeiro de 2024 a dezembro de 2025
-------------	------------------------------------

Validação	Janeiro a junho de 2026
-----------	-------------------------

Teste	Julho a dezembro de 2026
-------	--------------------------

Utilize a validação para orientar escolhas e ajustes. O conjunto de teste deverá ser reservado para a avaliação final.

Estatísticas de imputação, escalas e demais transformações aprendidas deverão ser calculadas apenas com os dados de treinamento durante essa avaliação.

É permitido utilizar bibliotecas como scikit-learn no notebook. Não é obrigatório utilizar algoritmos gerenciados do SageMaker ou publicar um endpoint.

Etapla 5 — Inferência e armazenamento dos resultados

Aplique o processo de preparação aos registros de dados_inferencia.csv e gere uma previsão para cada combinação de data, loja e produto.

O arquivo final deverá conter, no mínimo:

Coluna	Conteúdo
---------------	-----------------

dataset_id	Identificador do conjunto recebido
data	Data da previsão
loja	Identificador da loja
produto	Identificador do produto
quantidade_prevista	Quantidade estimada pelo modelo

Salve o resultado como **previsoes.csv no Amazon S3**.

A saída deverá preservar todas as chaves do arquivo de inferência, sem repetições ou previsões ausentes. As quantidades previstas não poderão ser negativas. Valores decimais são aceitos.

4. Entregáveis

A dupla deverá entregar:

1. **Relatório técnico em PDF**, contendo:
 - Identificação dos integrantes e do dataset;
 - Diagrama da arquitetura implementada; (Use [ícones de arquitetura da AWS](#))
 - Organização dos dados no S3;
 - Problemas encontrados e tratamentos realizados;
 - Resultados das consultas e sua interpretação;
 - Atributos utilizados, divisão temporal e modelo escolhido;
 - Comparação das métricas com a previsão de referência;
 - Limitações da solução.
2. **Código da solução**: rotina do Glue, consultas SQL e notebook de modelagem, com instruções suficientes para reprodução.
3. **Arquivo previsoes.csv**, também armazenado no S3.
4. **Evidências de execução**, demonstrando o processamento no Glue, as consultas no Athena, a execução do notebook e o armazenamento das previsões.

Capturas de tela complementam a entrega, mas não substituem os códigos e os resultados.

5. Critérios de avaliação

Critério	Pontuação
Ingestão e organização dos dados no S3	1,0
Catalogação e preparação com AWS Glue	2,0
Consultas e interpretação com Amazon Athena	1,5

Modelagem, avaliação temporal e justificativas 2,5

Inferência e armazenamento das previsões 1,5

Documentação, evidências e reprodutibilidade 1,5

Total 10,0

A avaliação considerará o funcionamento integrado da solução e a coerência das decisões. **A nota não será determinada exclusivamente pelo menor erro do modelo.** Serão valorizados o tratamento fundamentado dos dados, a prevenção de vazamento de informação e a interpretação correta das métricas.

6. Orientações gerais

- Utilize exclusivamente o dataset atribuído à dupla.
- Ambos os integrantes deverão conhecer e ser capazes de explicar a solução.
- Utilize os recursos e as permissões disponibilizados no Learner Lab ou no Free Tier.
- Não inclua credenciais ou chaves de acesso nos arquivos entregues.
- Interrompa recursos de computação quando não estiverem em uso.
- Registre eventuais limitações do ambiente. Se alguma impedir uma etapa obrigatória, comunique o professor para definição de uma alternativa.
- Identifique materiais, códigos e ferramentas de apoio utilizados. A dupla é responsável por verificar e explicar tudo o que entregar.
- Lembre-se que o Learner Lab é persistente entre sessões. Quando o cronômetro da sessão for zerado, a sessão terminará, mas todos os dados e os recursos criados na conta da AWS serão retidos. Se iniciar uma nova sessão (por exemplo, no dia seguinte), você verá que seu trabalho ainda estará no ambiente de laboratório.

Implementei esta avaliação para ver se teriam as permissões necessárias, vejam os prints de cada serviço:

Print of the AWS Management Console home page (Página inicial do console) for the user 'voclabs/user5306336= Student_View_Mateus_Fulni' in the 'us-east-1' region.

The page displays various widgets and sections:

- Visitado recentemente** (Recently visited): AWS Glue, Athena, Amazon SageMaker AI, Amazon SageMaker, S3, CloudWatch, IAM.
- Bem-vindo à AWS** (Welcome to AWS): Links to 'Primeiros passos com a AWS' (First steps with AWS) and 'Treinamento e certificação' (Training and certification).
- AWS Health**: Shows 'Problemas em aberto' (0), 'Alterações programadas' (1), and 'Outras notificações' (0).
- Custo e uso** (Cost and usage): Displays 'Mês atual' (Current month) as US\$ 0,00 and 'Previsão para o final do mês' (Forecast for the end of the month) as US\$ 0,07. Includes a bar chart showing costs for SageMaker, CloudWatch, Key Management Service, CloudShell, EC2 - Compute, and Outros.
- Soluções** (Solutions): Lists approved AWS solutions for commercial and technical cases, including 'Inteligência artificial' (4) and 'Segurança' (4).
- Explore a AWS** (Explore AWS): Features 'Amazon Redshift', 'Amazon S3', 'AWS Fargate', and 'AWS Marketplace'.
- Security**: Shows 'Região: US East (N. Virgínia)' and a 'Sem dados de segurança' (No security data) message, with a 'Comece a usar' (Get started) button.

The footer includes links to CloudShell, Kit de ferramentas de agentes para a AWS, Comentários, and copyright information for Amazon Web Services, Inc. (© 2026).

Amazon S3

<

▼ Buckets

Buckets de uso geral

Buckets de diretório

Buckets de tabela

Buckets de vetores

▼ Arquivos

Sistemas de arquivos

▼ Gerenciamento de acesso e segurança

Pontos de acesso

Pontos de acesso para FSx

Access Grants

IAM Access Analyzer

▼ Gerenciamento e insights de armazenamento

Lente de Armazenamento

Operações em lotes

Configurações de conta e organização

▶ AWS Marketplace para S3

prova-bigdata-ml-ref-008720354725

Informações

ObjetosMetadadosPropriedadesPermissõesMétricas

Objetos (9)

Copiar URI do S3

Copiar URL

Fazer download

Abri

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inve](#) outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a e

Localizar objetos por prefixo

☐	Nome	Tipo	Última modif
☐	athena-results/	Pasta	-
☐	glue-scripts/	Pasta	-
☐	inference/	Pasta	-
☐	ml/	Pasta	-
☐	notebooks/	Pasta	-
☐	predictions/	Pasta	-
☐	processed_\$folder\$	-	20 Sep 2026 C
☐	processed/	Pasta	-
☐	raw/	Pasta	-

CloudShell

us-east-1

+

```
~ $ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --output
```

Custom Educators Dashboard

Iniciar os laboratórios de apri

Crawlers - AWS Glue Console

JupyterLab

←↻🔒https://us-east-1.console.aws.amazon.com/glue/home?region=us-east-1#/v2/data-catalog/crawlers

aws

Search

[Alt+S]

AWS Glue

> Crawlers

Getting started

SageMaker Unified Studio

ETL jobs

Visual ETL

Notebooks

Job run monitoring

Data Catalog tables

Data connections

Workflows (orchestration)

Zero-ETL integrations

New

► Data Catalog

► Data Integration and ETL

► Legacy pages

What's New

Documentation

AWS Marketplace

Enable compact mode

Enable new navigation

Crawlers

A crawler connects to a data store, progresses through a prioritized list of classifiers to determine

Crawlers (2)

help

View and manage all available crawlers.

Filter crawlers

☐	Name	State	Schedule
☐	processed-vendas-crawler	Ready	
☐	raw-vendas-crawler	Ready	

CloudShell

us-east-1

+

~\$ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --output

Custom Educators Dashboard

Iniciar os laboratórios de apr

Jobs - AWS Glue Studio

JupyterLab

https://us-east-1.console.aws.amazon.com/gluestudio/home?region=us-east-1#/jobs

aws

Search

[Alt+S]

AWS Glue

Jobs

AWS Glue

Getting started

SageMaker Unified Studio

ETL jobs

Visual ETL

Notebooks

Job run monitoring

Data Catalog tables

Data connections

Workflows (orchestration)

Zero-ETL integrations

Data Catalog

Data Integration and ETL

Legacy pages

What's New

Documentation

AWS Marketplace

Enable compact mode

Enable new navigation

Try generative AI upgrades for Apache Spark with AWS Glue in preview

You can now quickly upgrade and modernize your existing Spark jobs from an older version

more

Choose Upgrade with AI in Actions to get started.

Notificações

AWS Glue Studio

Get Started

Visual ETL

Notebook

Example jobs

Your jobs (1)

Filter jobs by property

Job name	Type	Created by	Last modified
etl-vendas-varejo01	Glue ETL	Script	20/09/2026, 19:

CloudShell

us-east-1

\$ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --output

Custom Educators Dashboard

Iniciar os laboratórios de apr

Tables - AWS Glue Console

JupyterLab

https://us-east-1.console.aws.amazon.com/glue/home?region=us-east-1#/v2/data-catalog/tables?database=prova_multidisciplinar

aws

Search

[Alt+S]

Tables

AWS Glue

Getting started

SageMaker Unified Studio

ETL jobs

Visual ETL

Notebooks

Job run monitoring

Data Catalog tables

Data connections

Workflows (orchestration)

Zero-ETL integrations

Data Catalog

Data Integration and ETL

Legacy pages

What's New

Documentation

AWS Marketplace

Enable compact mode

Enable new navigation

Announcing enhancements to Glue statistics

We've added the option to schedule incremental stats generation, and stats for Iceberg tabl

Notifications

0

0

Your catalog, more capabilities

Discover, govern, and trust your data in SageMaker Unified Studio with AI-po

Tables

A table is the metadata definition that represents your data, including its schema. A table can be u

Tables (2)

View and manage all available tables.

Choose catalog

008720354725

Choose database

prova_multidisciplinar_db

Filter tables

	Name	Database	Location	Classification
☐	processed_vendas	prova_multidisciplir	s3://prova-bigdata-	Parquet
☐	raw_vendas	prova_multidisciplir	s3://prova-bigdata-	CSV

CloudShell

us-east-1

~ \$ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --output

Custom Educators Dashboard | Iniciar os laboratórios de ap... | Editor de consultas | Athena | JupyterLab

https://us-east-1.console.aws.amazon.com/athena/home?region=us-east-1#/query-editor/history

aws

Pesquisar

[Alt+S]

Amazon Athena > Editor de consultas



Consultar no Estúdio Unificado Amazon SageMaker

Utilize seu perfil do IAM para analisar e criar com seus recursos da AWS existentes em um único ambiente de desenvolvi

Editor

Consultas recentes

Consultas salvas

Configurações de consultas

Consultas recentes (10)

Pesquisar consultas recentes

	ID de execução	Consulta	H
☐	1e6bbfb4-8b9f-489c-9b2b-bc3aab545718	SELECT loja, categoria, AVG(quantidade_vendida) AS media_v...	20
☐	0b5876e5-bac7-46e7-96b2-37ee8663ee4b	SELECT promocao, AVG(quantidade_vendida) AS media_vendi...	20
☐	fcd1ba99-f574-4d2c-ba74-9cdb27e8f828	SELECT ano, mes, SUM(quantidade_vendida) AS total_vendido...	20
☐	f5f498a6-1123-4624-9b2d-ec0b10c7e74e	SELECT produto, SUM(quantidade_vendida) AS total_vendido ...	20
☐	a2f89317-5b74-4519-bae4-3575eba04f47	SELECT (SELECT COUNT(*) FROM raw_vendas) AS registros_br...	20
☐	13aa6e59-1852-4360-8ac7-ffde04939e27	SELECT loja, categoria, AVG(quantidade_vendida) AS media_v...	20
☐	4259c109-b394-4012-b75e-9c01ad342759	SELECT promocao, AVG(quantidade_vendida) AS media_vendi...	20
☐	af98d9df-8d9a-40e4-af6d-ed4c02cc1a01	SELECT ano, mes, SUM(quantidade_vendida) AS total_vendido...	20
☐	7356d64a-aacd-4029-b6df-4833758229ec	SELECT produto, SUM(quantidade_vendida) AS total_vendido ...	20
☐	a518ce41-e38d-455d-920b-a2557df9f31f	SELECT (SELECT COUNT(*) FROM raw_vendas) AS registros_br...	20

CloudShell

us-east-1

```
~ $ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --outpu
```

Custom Educators Dashboard

Iniciar os laboratórios de apr

Instâncias do bloco de anot

JupyterLab

←↻🔒https://us-east-1.console.aws.amazon.com/sagemaker/home?region=us-east-1#/notebook-instances

aws

Pesquisar

[Alt+S]

IA do Amazon SageMaker

Instâncias do bloco de anotações

IA do Amazon SageMaker

Dashboard

What's new43

▼ Environment configuration

Domínios

Imagens

Configurações do ciclo de vida

Gerente de perfis

▼ Applications and IDEs

SageMaker Studio

Tela

RStudio

Notebooks

TensorBoard

Profiler

Partner AI Apps

▼ Model training & customization

Training & tuning jobs

JumpStart model hub

Nova Forge

HyperPod clusters

▶ Training plans

▶ Deployments & inference

▶ Model governance

▶ AWS Marketplace resources

▶ Data preparation

▶ Ground Truth

▶ IA aumentada

Tutoriais

Instâncias do bloco de anotações

Localizar instâncias do bloco de anotações

Nome	Instância	Hora c
varejo01-referencia	ml.t3.medium	20/09

CloudShell

us-east-1

~\$ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --outpu

Custom Educators Dashboard

Iniciar os laborat3rios de aprendi...

Solucao, Refe... - JupyterLab

https://varejo01-referencia.notebookus-east-1.sagemaker.aws/lab/tree/Solucao_Referencia_VAREJO_01.ipynb

File Edit View Run Kernel Git Tabs Settings Help

Launcher

Solucao_Referencia_VAREJO_01.X

Open in... conda_python3

Y

Name

Modified

execucao.log 9m ago

execucao2.log 1h ago

execucao3.log 1h ago

execucao4.log 1h ago

execucao5.log 1h ago

execucao6.log 1h ago

install.log 1h ago

previsoes_VAREJO... 1h ago

Solucao_Referenci... next yr.

Solucao de Referencia - VAREJO_01

Prova Multidisciplinar: Infraestrutura de Big Data + Paradigmas e Tecnologias Emergentes em Ciencia de Dados

Pipeline: Dataset local -> S3 (raw) -> Glue ETL -> S3 (processed, Parquet) -> Glue Data Catalog -> Athena -> SageMaker (este notebook) -> Treinamento -> Avaliacao -> Inferencia -> S3 (predictions).

Este notebook consome os dados ja processados pelo Glue (processed/ventas/), forma o problema de ML, remove o atributo de data leakage, treina e avalia um modelo, e gera previsoes em lote para inference/dados_inferencia.csv.

Secao 1 - Configuracao

[]: import sys, subprocess
for pkg in ["s3fs", "pyarrow"]:
 try:
 __import__(pkg)
 except ImportError:
 subprocess.run([sys.executable, "--m", "pip", "install", "--q", pkg])

import boto3
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.dummy import DummyRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.preprocessing import OneHotEncoder
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

Nenhuma credencial e' gravada aqui: o notebook usa a role de execucao do SageMaker (labRole)
BUCKET = "prova-bigdata-ml-ref-008720354725"
PROCESSED_PATH = f"s3://{BUCKET}/processed/ventas/
INFERENCE_PATH = f"s3://{BUCKET}/inference/dados_inferencia.csv"
PREDICTIONS_PATH = f"s3://{BUCKET}/predictions/previsoes_VAREJO_01.csv"

print("BUCKET:", BUCKET)
print("PROCESSED_PATH:", PROCESSED_PATH)
print("INFERENCE_PATH:", INFERENCE_PATH)
print("PREDICTIONS_PATH:", PREDICTIONS_PATH)

Secao 2 - Carregamento dos dados processados

[]: df = pd.read_parquet(PROCESSED_PATH)
print("Linhas:", df.shape[0], "| Colunas:", df.shape[1])
print("\nTipos de dados:")
print(df.dtypes)
print("\nValores ausentes por coluna:")
print(df.isna().sum())
print("\nEstatisticas basicas (numericas):")
df.describe()

[]: df.head(10)

Secao 3 - Formulacao do problema

Objetivo de negocio: prever a demanda diaria de produtos (quantidade_vendida) por loja e produto, para apoiar decisoes de reposicao de estoque e planejamento de promocoes.

Variavel alvo: quantidade_vendida (unidades vendidas no dia, por loja/produto).

Tipo de problema: regressao com componente temporal (serie temporal por loja/produto). A ordem cronologica dos dados deve ser respeitada: nao podemos treinar com dados do futuro para prever o passado, e a divisao treino/teste deve preservar a sequencia temporal (ver Secao 7), ao inves de uma divisao aleatoria.

Secao 4 - Analise temporal

[]: df["data"] = pd.to_datetime(df["data"])

Tendencia: total vendido por mes
mensal = df.groupby(df["data"].dt.to_period("M"))["quantidade_vendida"].sum()
plt.figure(figsize=(10, 4))
mensal.plot(kind="line", markers="o")
plt.title("Tendencia: quantidade total vendida por mes")

Would you like to get notified about official Jupyter news?
Open privacy policy Yes No

Simple 1 conda_python3 | title Fully initialized Mode: Command Ln 1, Col 1 Solucao_Referencia_VAREJO_01.ipynb 1

Custom Educators Dashboard

Iniciar os laboratórios de apri

prova-bigdata-ml-ref-008720

JupyterLab

←

↺

https://us-east-1.console.aws.amazon.com/s3/buckets/prova-bigdata-ml-ref-008720354725?region=us-east-1&prefix=predictions/

aws

Pesquisar

[Alt+S]

Amazon S3

Buckets

prova-bigdata-ml-ref-008720354725

predictions/

Amazon S3

<

predictions/

▼ Buckets

Buckets de uso geral

Buckets de diretório

Buckets de tabela

Buckets de vetores

▼ Arquivos

Sistemas de arquivos

▼ Gerenciamento de acesso e segurança

Pontos de acesso

Pontos de acesso para FSx

Access Grants

IAM Access Analyzer

▼ Gerenciamento e insights de armazenamento

Lente de Armazenamento

Operações em lotes

Configurações de conta e organização

▶ AWS Marketplace para S3

Objetos

Propriedades

Objetos (1)

Copiar URI do S3

Copiar URL

Fazer download

Abri

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inve](#) outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a e

Localizar objetos por prefixo

☐

Nome

▲

Tipo

▼

Última modif

☐

previsoes_VAREJO_01.csv

csv

20 Sep 2026 C

CloudShell

us-east-1

+

~\$ clear; aws sagemaker describe-notebook-instance --notebook-instance-name varejo01-referencia --query NotebookInstanceStatus --outpu